

RAPPORT DE SYNTHÈSE : PRÉDICTION DU DÉFAUT DE PRÊT IMMOBILIER

1 – Compréhension de la problématique

- **Défi** : Réduire les pertes financières bancaires liées aux non-remboursements de crédits immobiliers.
- **Objectif** : Prédire la probabilité qu'un demandeur fasse défaut.
- **Variable cible** : Status (classification binaire : 1 pour défaut, 0 pour remboursement normal).

2 – Analyse exploratoire des données (EDA)

- **Volume** : 148 670 lignes, 34 colonnes.
- **Distribution de la donnée cible** : dataset non équilibré ~75 % de bons payeurs (Status = 0) / ~25 % de défauts (Status = 1).
- **Nettoyage** : Suppression immédiate des variables inutiles (ID et year).
- Suppression des lignes présentant plus de 7 colonnes vides (~527 lignes).
- **Taux de remplissage des données** : Fort taux de valeurs manquantes sur les variables (Upfront_charges, 26.6 %), (Interest_rate_spread, 24.6 %), (rate_of_interest, 24.5 %), (dtir1, 16.2 %) et (LTV et property_value, 10.16 %).
- Le dataset comporte 10 variables numériques et 21 variables catégorielles.
- Étude de corrélation entre variables indépendantes : loan_amount et property_value sont fortement corrélées (0.73), rate_of_interest et interest_rate_spread sont corrélées (0.61), income et loan_amount (0.46), income et property_value (0.41).

3 - Pré-processing des données

- Split Train/Test avec test_size = 0.30 et stratify = y pour conserver la distribution initiale.
- **Traitement des valeurs manquantes dans les attributs numériques** :
 - o Term → most frequent
 - o Income → median
 - o Interest_rate_spread & rate_of_interest → IterativeImputer
 - o property_value → IterativeImputer
 - o dtir1 → median
 - o Upfront_charges → mean
 - o LTV = loan_amount / property_value
- Traitement des valeurs manquantes pour les variables catégorielles : ajout d'une nouvelle catégorie "Unknown".
- **Détection et suppression des outliers** : selon la méthode de Tukey, les outliers ont des valeurs inférieures à $Q1 - 1.5(Q3 - Q1)$ ou supérieures à $Q3 + 1.5(Q3 - Q1)$. Cette étape est réalisée uniquement sur les données de Train.

- Encoding des variables catégorielles : One-Hot Encoding et suppression des variables catégorielles initiales.
- Normalisation : centrage et réduction (StandardScaler) des variables pour harmoniser les échelles en utilisant les métriques issues du Train.
- Reproduction de toutes les étapes ci-dessus sur le dataset de test en appliquant uniquement transform (à l'exception de la suppression des outliers).
- **Sélection des variables :**
 - Détermination de l'importance par RandomForest.
 - Utilisation de la méthode robuste RFECV pour ne conserver que les indicateurs les plus prédictifs.
 - Évaluation du modèle RandomForest avec les variables jugées importantes.
 - Réajustement.
 - Choix final de 6 variables : ['property_value', 'dtir1', 'LTV', 'income', 'loan_amount', 'Credit_Score'].

4 - Construction des modèles ML

- **Stratégie :** Évaluation comparative de près de 10 algorithmes.
- Modèles linéaires : Régression Logistique, RidgeClassifier et Stochastic Gradient Descent (SGD).
- Modèle à base d'arbre : Arbre de Décision.
- Méthodes d'ensemble : Random Forest, Extra Trees, AdaBoost, Gradient Boosting et XGBoost.
- Méthode basée sur la distance : K-Nearest Neighbors (KNN).
- **Constat :** Les algorithmes basés sur des arbres de décision ont largement surperformé les modèles linéaires, car ils capturent mieux les relations non linéaires et tolèrent les valeurs aberrantes (outliers) sans altération significative.

Après comparaison des différents scores, notamment le ROC-AUC et le Recall, le choix s'est arrêté sur ces trois modèles : RandomForest, XGBoost et Gradient Boosting.

5 - Tuning des trois modèles candidats et choix du modèle final

- **Optimisation :** Recherche par grille (GridSearchCV) couplée à une validation croisée stratifiée à 5 blocs (StratifiedKFold).
 - **Modèle retenu :** XGBoost. Il a fourni les meilleures métriques de généralisation (score ROC-AUC maximal) sur le jeu de test. Le Recall reste néanmoins bas (dataset non équilibré).
-

6 - Déploiement du modèle

- Sérialisation du modèle final et du pipeline complet avec joblib (y compris le preprocessing appliqué aux variables sélectionnées).
- Le fichier binaire du pipeline final est nommé pipeline_credit_xgboost.joblib.

7 – Application déployée sur Streamlit Cloud

- Application Streamlit permettant d’entrer les informations du demandeur et d’obtenir la probabilité de défaut. Elle est déployée sur streamlit Cloud sur le lien suivant :

<https://creditriskml-alcb2luy4fyqt9pxl9vvdv.streamlit.app/>

Application Score de Crédit

Saisie des données du client

Revenu	3500	- +
Valeur du bien	200000	- +
Taux endettement (dtir1)	33,00	- +
LTV (laisser 0 pour calcul automatique)	0,00	- +
Montant du pret	150000	- +
Credit Score	650	- +
Calculer la prédiction		

8 - Application Flask déployée sur Render

- **Rôle** : Solution d’API web de niveau production.
- **Infrastructure** : Utilisation de Gunicorn comme serveur HTTP.

My project
Production
CreditRisk_ML

Search
New
Upgrade
H

WEB SERVICE

CreditRisk_ML

Python 3

Free

Upgrade your instance →

Service ID: srv-d8j99767r5hc73dlco9g

hafidaE / CreditRisk_ML main

https://creditrisk-ml.onrender.com

Connect
Manual Deploy

Your free instance will spin down with inactivity, which can delay requests by 50 seconds or more.
Upgrade now

June 8, 2026 at 11:27 AM

Live

49fe9e8 Add files via upload

All logs
Search
Jun 8, 11:26 AM - 11:31 AM
GMT+1

```


Jun 8
11:30:07 AM [rrgjd] 127.0.0.1 - - [08/Jun/2026:10:30:07 +0000] HEAD / HTTP/1.1 200 0 "https://creditrisk-ml.onrender.com/" Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/148.0.0.0 Safari/537.36"
11:30:08 AM [rrgjd] 127.0.0.1 - - [08/Jun/2026:10:30:08 +0000] "GET / HTTP/1.1" 200 1046 "https://creditrisk-ml.onrender.com/" Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/148.0.0.0 Safari/537.36"
11:30:08 AM [rrgjd] 127.0.0.1 - - [08/Jun/2026:10:30:08 +0000] "GET /favicon.ico HTTP/1.1" 404 207 "https://creditrisk-ml.onrender.com/" Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/148.0.0.0 Safari/537.36"
11:30:08 AM ==> Your service is live
11:30:08 AM [rrgjd] 127.0.0.1 - - [08/Jun/2026:10:30:08 +0000] "GET / HTTP/1.1" 200 1046 "-" Go-http-client/2.0"
11:30:08 AM ==>
11:30:08 AM ==>

```

• **Logique métier** : Réception des données via une requête POST (formulaire HTML), exécution du pipeline XGBoost et application d'un seuil de décision strict à 25 % :

- o Si Probabilité de défaut $\geq 25\%$ → CRÉDIT REFUSÉ
- o Si Probabilité de défaut $< 25\%$ → CRÉDIT ACCORDÉ

Le lien de l'application : <https://creditrisk-ml.onrender.com> (si il n'est plus accessible c'est à cause de la suppression des données de paiement)



Système d'Évaluation du Risque de Crédit

Revenu Mensuel (€) :

Valeur du Bien (€) :

Taux d'endettement (%) :

LTV (% - optionnel) :

Montant du Prêt (€) :

Score de Crédit :

Lancer la prédiction